AJACS「シングルセルRNA-seqを知って・学んで・使う」 (2024年12月23日・オンライン)

公共データベースから シングルセルRNA-segデータを取得する

理化学研究所 生命医科学研究センター(IMS) 生命医科学大容量データ技術研究チーム チームリーダー

粕川 雄也

講義内容の概要

目的

- シングルセルRNA-seqのデータをまだ持っていない人や、取得前に解析の練習をしてみたい人が、公開リソースからデータを入手できるようになること
- その他、シングルセルRNA-seqに関する情報を入手できる場所を知ること

• 内容

- ・シングルセルRNA-segの主なデータ形式
- シングルセルRNA-segが入手できるリポジトリ
- ダウンロードしたファイルを解析ソフトウェアで使う
- シングルセルRNA-seq解析に有用なウェブサイト

シングルセルRNA-seqの主なデータ形式

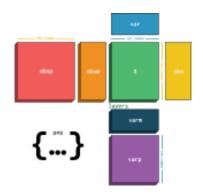
シングルセルRNA-segの主な公開データ形式

FASTQ形式 - 配列ならびにそのクオリティスコアが含まれるファイル

```
@SRR9291388.1 K00125:97:HLHLYBBXX:3:1101:2980:998 length=26
NGCACCTAGTCTCAACGTTCTACCAA
+SRR9291388.1 K00125:97:HLHLYBBXX:3:1101:2980:998 length=26
#AAFFJJJJFFJJJJJJJJJJJJJJJ
```

BAM形式 - ゲノムへのマッピング結果のファイル

• H5AD形式 - 遺伝子ごとの発現量テーブル、細胞アノテーション、次元削減(クラスタリング)の結果が含まれるファイル



シングルセルRNA-segが入手できるリポジトリ

INSDC (International Nucleotide Sequence Database Collaboration) (DDBJ / NCBI / EMBL-EBI)

INSDC (DDBJ / NCBI / EMBL-EBI)

- 新規シーケンスを用いた論文を発表するときには、そのシーケンスデータを 公開することが原則的に義務化されている(個人情報関連については例外等 もあり)
- その登録先のリポジトリを DDBJ (日本)、NCBI(米国)、EBI(欧州)が運営しており、誰でもデータを入手可能である

	DDBJ	NCBI	EMBL-EBI
機能ゲノミクス データ	<u>GEA</u>	<u>GEO</u>	<u>ArrayExpress</u>
シーケンスデータ	DDBJ SRA (DRA)	<u>SRA</u>	<u>ENA</u>
サンプル情報	<u>BioSample</u>	<u>BioSample</u>	<u>BioSamples</u>
プロジェクト情報	<u>BioProject</u>	<u>BioProject</u>	BioProject

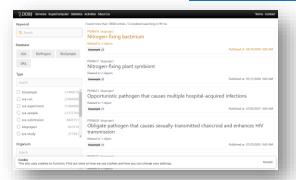
INSDC - アクセッション番号

公開データの参照に使われる「アクセッション番号」
https://ena-docs.readthedocs.io/en/latest/submit/general-guide/accessions.html

- •BioProject: "PRJ" + "E/N/D" + (アルファベット1文字) + (数字)
- •SRA/DRA/ENAの "submission": "E/D/S" + "RA" + (数字)
- •SRA/DRA/ENAの "Run": "E/D/S" + "RR" + (数字)
- •NCBI GEO: "GSE" + (数字)
 - ArrayExpress上では "E-GEOD"+(数字)
- ArrayExpress: "E-MTAB-" + (数字)
- •DDBJ GEA: "E-GEAD" + (数字)

INSDC - ウェブサイトからダウンロード

- •BioProject や SRA/DRA/ENA のアクセッション番号
 - DDBJ DRA: https://ddbj.nig.ac.jp/search/
 - NCBI SRA: https://www.ncbi.nlm.nih.gov/sra/
 - EMBL ENA: https://www.ebi.ac.uk/ena/browser/search







- NCBI GEOやArrayExpressionのアクセッション番号
 - NCBI GEO: https://www.ncbi.nlm.nih.gov/gds/
 - ArrayExpress: https://www.ebi.ac.uk/biostudies/arrayexpress





INSDC - ダウンロードツールの利用

- SRAtoolkit の fasterq-dump コマンドを使って、直接FASTQファイル をダウンロードすることも可能
 - ・ 欲しいデータの SRA/DRA/ENAの "Run" アクセッション番号のリスト
 - BioProjectやSRAの他のアクセッション番号しか分からない場合は、ウェブサイト検索で取得するか、Entrez Direct がインストールされていれば、以下で取得可能

```
$ esearch -db sra -query (アクセッション番号) | efetch -format runinfo | cut -f 1 -d ',' 🖟
```

• fasterg-dump コマンドの基本的な書き方は以下のとおり

```
$ fasterq-dump -S --include-technical (アクセッション番号) 🛭
```

インストール方法について

[SRA Toolkit] https://github.com/ncbi/sra-tools/wiki/02.-Installing-SRA-Toolkit [Entrez Direct] https://www.ncbi.nlm.nih.gov/books/NBK179288/

Debian/Ubuntu ではapt から、pip/biocondaでもインストール可能なものもあり

シングルセルRNA-segが入手できるリポジトリ

Human Cell Atlas

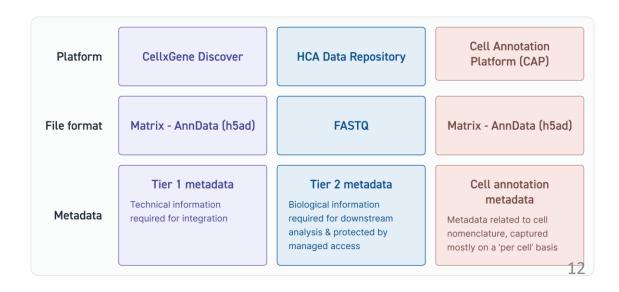
Human Cell Atlas

- ・ヒトのすべての細胞のリファレンスマップの構築を目指す、国際共同プロジェクト
- ・現在は肝臓や脂肪組織など18種類の「biological network」を対象にトランスクリプトームベースのリファレンスマップ (V1 Atlas)を構築中
 - その後、マルチオミックスのデータや、空間トランスクリプトームのデータへ拡張予定
- 2024年11月に first draft atlas に関する一連の論文が発表
 - https://www.nature.com/collections/jccbbdahji
- HCAのウェブサイト: https://www.humancellatlas.org/



Human Cell Atlas - データプラットフォーム

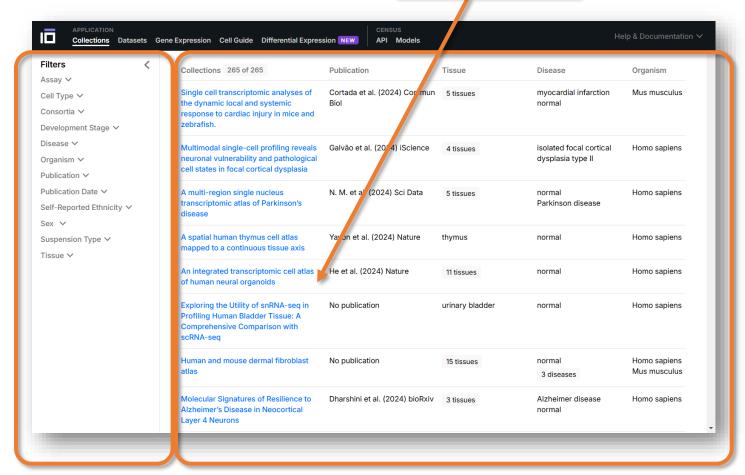
- 3種類のデータプラットフォームがある(最近再構成された模様)
 - CellxGene Discover: https://cellxgene.cziscience.com/collections
 - 遺伝子発現プロファイル+データセットに関する最小限のメタデータ
 - HCA Data Repository: <u>https://explore.data.humancellatlas.org/projects</u>
 - FASTQファイル+サンプルに関する詳細なメタデータ(reference atlas構築に必要な詳細情報)
 - 今後は制限アクセス(ヒト由来サンプル等)用に使われる
 - Cell Annotation Platform: https://celltype.info/
 - 遺伝子発現プロファイル+細胞に関する詳細情報(細胞種等)



Human Cell Atlas - CellxGene discover (1)

https://cellxgene.cziscience.com/collections

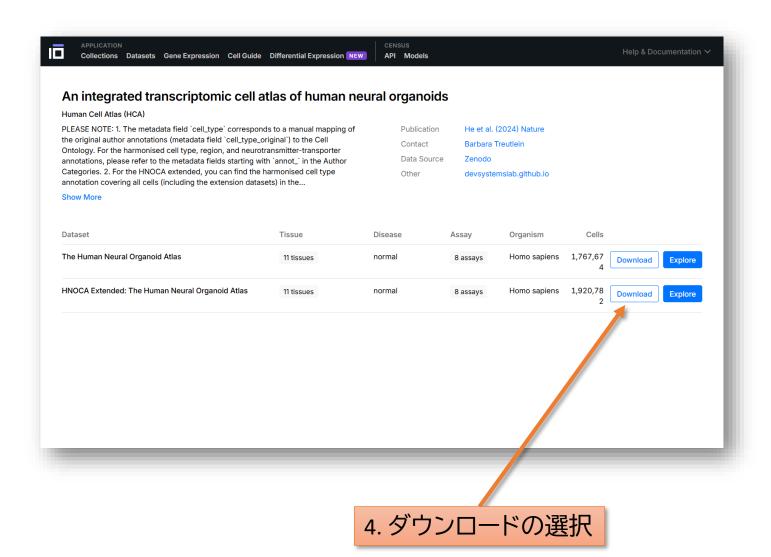
3. データの選択



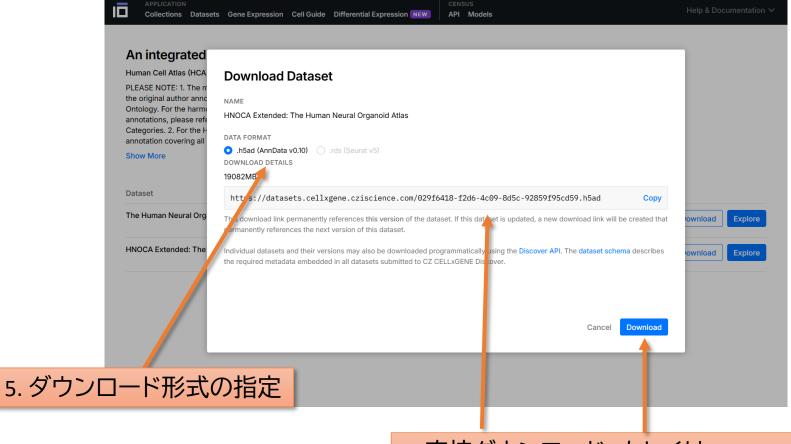
1. データの選択条件の指定

2. 条件に合致する候補データの一覧

Human Cell Atlas - CellxGene discover (2)

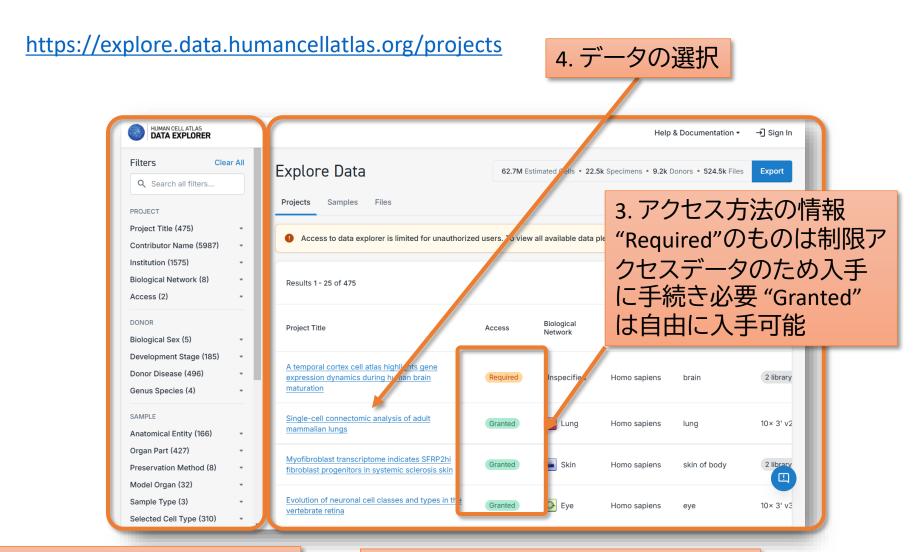


Human Cell Atlas - CellxGene discover (3)



6. 直接ダウンロード、もしくは 指定されたURLでcurl等を用いてダウンロード

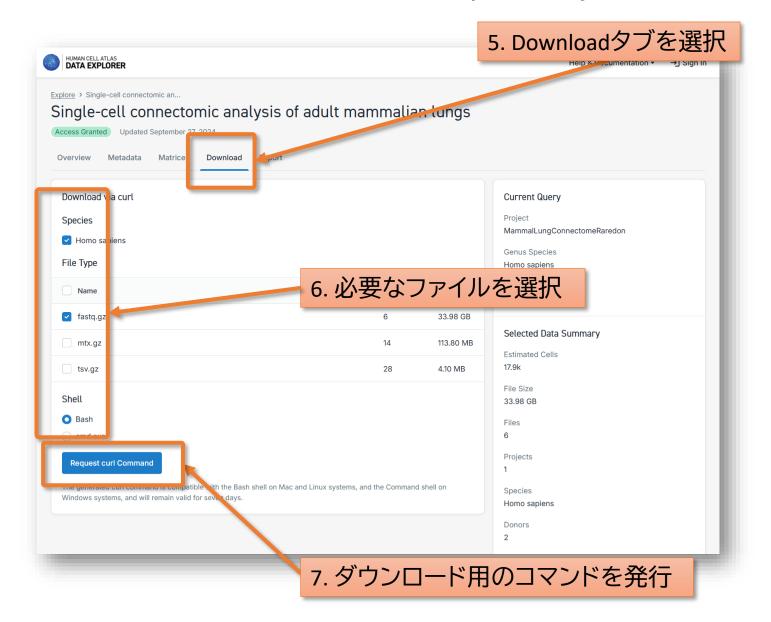
Human Cell Atlas – HCA Data Repository (1)



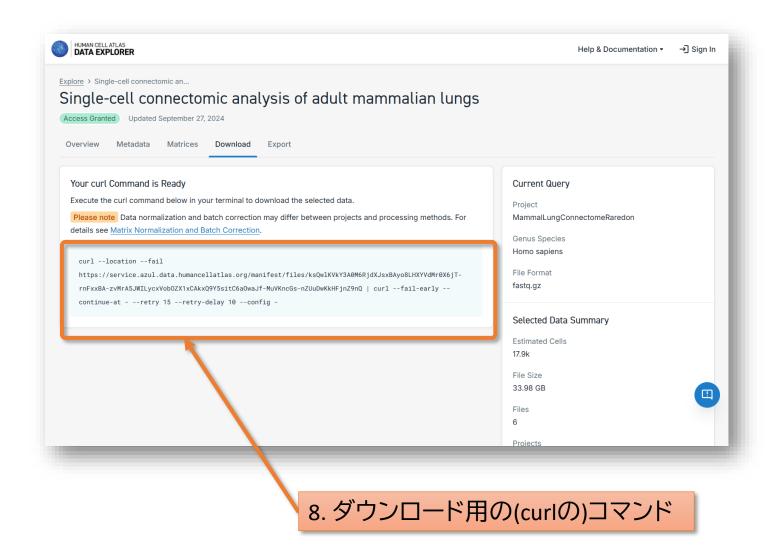
1. データの選択条件の指定

2. 条件に合致する候補データの一覧

Human Cell Atlas – HCA Data Repository (2)



Human Cell Atlas - HCA Data Repository (3)

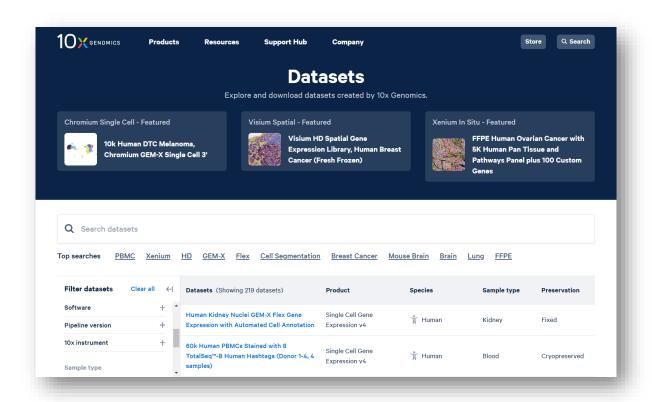


シングルセルRNA-segが入手できるリポジトリ

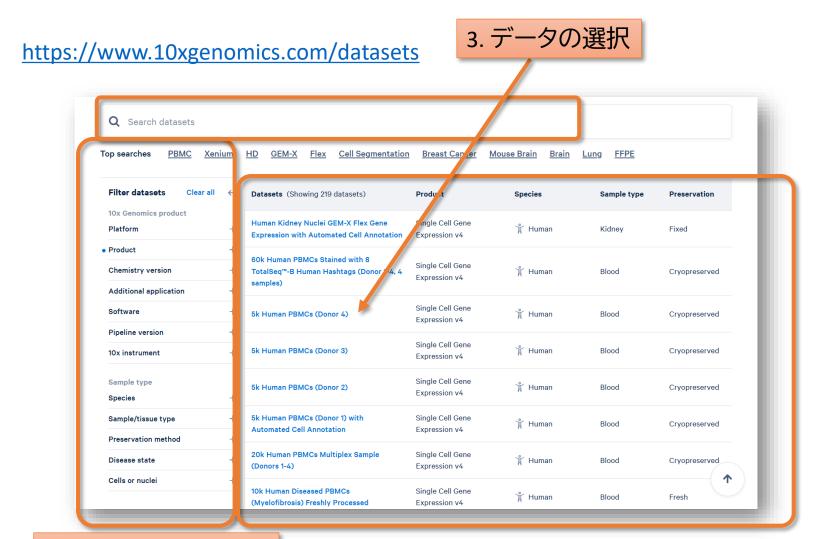
10x Genomics社の Dataset サイト

10x Genomics社の Dataset サイト

- •10x Genomics 社のウェブサイトで、10x Genomics社で取得したデータが公開されている
 - https://www.10xgenomics.com/datasets
 - Creative Commons Attribution licenseで公開
- ・何種類かのサンプルに対して、10x Genomics 社の様々なプロトコルで生産したデータが入手



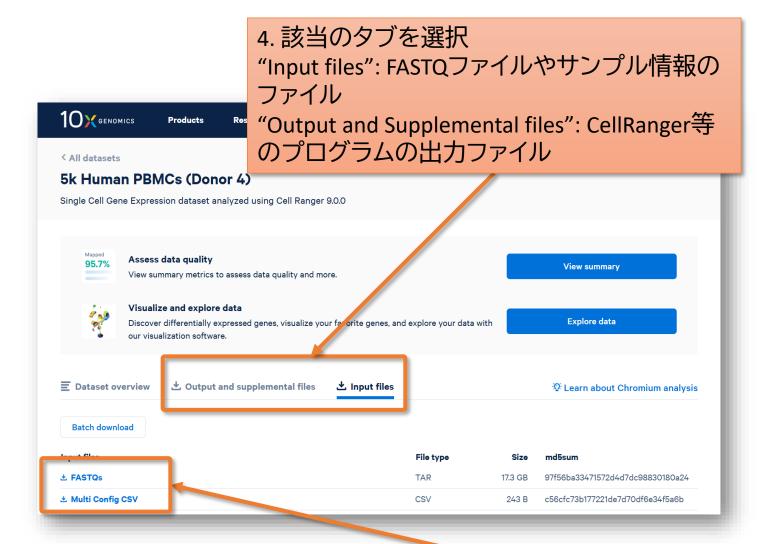
10x Genomics社の Dataset サイト (1)



1. データの選択条件・キーワードの指定

2. 条件に合致する候補データの一覧

10x Genomics社の Dataset サイト (2)



5. 該当ファイルの選択

ダウンロードしたファイルを解析ソフトウェアで使う

ダウンロードしたFASTQデータを CellRangerで使う

- 必要となるFASTQファイル
 - シングルセルRNA-seqの場合は、基本的に R1 (read1) と R2 (read2)のファイル があればよい(ただし、3' v1 chemistry を使っている場合は I1 (index1) ファイル が必要)

10x Genomics Library: Chemistry version	Recommended	Alternative
Gene Expression*: 3' v3.1, 3' LT v3.1, 3' v3, 3' v2, 5' v2, 5' v1.1, 5' v1	R1 and R2 FASTQs	10x BAM
	1. R1 and R2 FASTQs;	1. 10x BAM;
Visium FF & FFPE	2. Image (submitted as processed data file)	2. Image (submitted as processed data file)
Feature Barcode: Cell Surface Protein, CRISPR Screening	R1 and R2 FASTQs	10x BAM
3' CellPlex**	10x per-sample BAM (see here)	N/A
5' TCR/BCR***: v2, v1.1, v1	R1 and R2 FASTQs	N/A
Multiome Gene Expression	R1 and R2 FASTQs	10x BAM
Multiome ATAC****	10x BAM	N/A
ATAC***: v1.1, v1	10x BAM	N/A
Chromium Genome, Single Cell DNA	R1 and R2 FASTQs	10x BAM

^{*}Note that for 3' v1 chemistry, uploading only R1 and R2 FASTQ files is NOT sufficient for others to reproduce the analysis. In this version, 10x Genomics BAM file is the recommended file.

https://kb.10xgenomics.com/hc/en-us/articles/360024716391-What-format-of-10x-Genomics-data-should-l-submit-to-NCBI-GEO-SRA

・実験chemistryごとのread長の構成

	Read1 (R1)	i7 index (I1)	i5 index (I2)	Read2 (R2)
3' v4	<u>28</u>	10	10	Insert >=90
3' v3 DL	<u>28</u>	10	10	Insert >=90
3' v3/v3.1	<u>28</u>	8	-	Insert >=91
3' v2	<u>26</u>	8	-	Insert >=98
3' v1	Insert >=98	<u>14 (R3)</u>	8 (I1)	<u>10</u>
5' v3	28(+TSO+Insert)	10	10	Insert >=90
5' v2 DL	28(+TSO+Insert)	10	10	Insert >=90
5' v1/v1.1	26(+TSO+Insert)	8	-	Insert >=91

ダウンロードして得られた複数のFASTQファイルのうち、 どれが Read1 (R1)、Read2 (R2)、i7 index (I1) かをread長で推定する

- 処理の流れ(例: SRR9291388)
 - 1. FASTQファイルをダウンロード

```
$ fasterq-dump -S --include-technical SRR92913884
```

以下の3つのファイルが生成される

- SRR9291388 1.fastq
- SRR9291388 2.fastq
- SRR9291388_3.fastq
- 2. read長の確認をする

```
$ head -1 SRR9291388_*.fastq
```

```
==> SRR9291388_1.fastq <==
@SRR9291388.1 K00125:97:HLHLYBBXX:3:1101:2980:998 length=26

==> SRR9291388_2.fastq <==
@SRR9291388.1 K00125:97:HLHLYBBXX:3:1101:2980:998 length=98

==> SRR9291388_3.fastq <==
@SRR9291388.1 K00125:97:HLHLYBBXX:3:1101:2980:998 length=8
```

- 処理の流れ(例: SRR9291388)
 - 3. ファイルとReadの種類の対応づけと、ファイル名の変更

ダウンロードファイル名	Readの種類	CellRanger用ファイル名
SRR9291388_1.fastq	R1	SRR9291388_S1_L001_R1_001.fastq
SRR9291388_2.fastq	R2	SRR9291388_S1_L001_R2_001.fastq
SRR9291388_3.fastq	I1	SRR9291388_S1_L001_I1_001.fastq (なくてもよい)

CellRanger用のFASTQファイル名に変更する必要がある "[Sample Name]_S1_L00[Lane Number]_[Read Type]_001.fastq.gz"

(CellRanger 4.0以降は L00[Lane Number] は省略可能)

- 処理の流れ(例: SRR9291388)
 - 4. CellRanger の実行

```
$ cellranger count --id=(任意のID) --create-bam=true
--transcriptome=(reference transcriptomeファイルのあるディレクトリ)
--fastqs=(3.用意したFASTQファイルのあるディレクトリ) 🛭
```

実行例:

```
$ cellranger count --id=SRR9291388 --create-bam=true
--transcriptome=/data/refdata-gex-GRCh38-2024-A/
--fastqs=$HOME/work/fastqs/&
```

Chemistry は自動判定されるが、判定に問題がある場合は "--chemistry" オプションで明示的に指定する

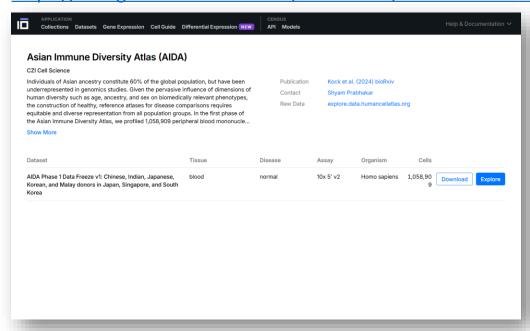
CellRangerプログラムと、reference transcriptome の設定は完了しているものとする

ダウンロードしたファイルを解析ソフトウェアで使う

ダウンロードしたH5ADファイルを Scanpy で使う

- 処理の流れ (Asian Immune Diversity Atlasのデータ)
 - 1. H5AD形式のファイルのダウンロード

https://cellxgene.cziscience.com/collections/ced320a1-29f3-47c1-a735-513c7084d508



最終的に "2a99fd19-9a29-48c3-9d65-47467fd7cefe.h5ad" というファイルがダウンロード される

ファイル名が長いので、以下"AIDA.h5ad" に変更して説明する

- 処理の流れ (Asian Immune Diversity Atlasのデータ)
 - 2. Python の scanpy パッケージをロードしデータの読み込み

```
import scanpy data aida = scanpy.read_h5ad('AIDA.h5ad',backed='r') d
```

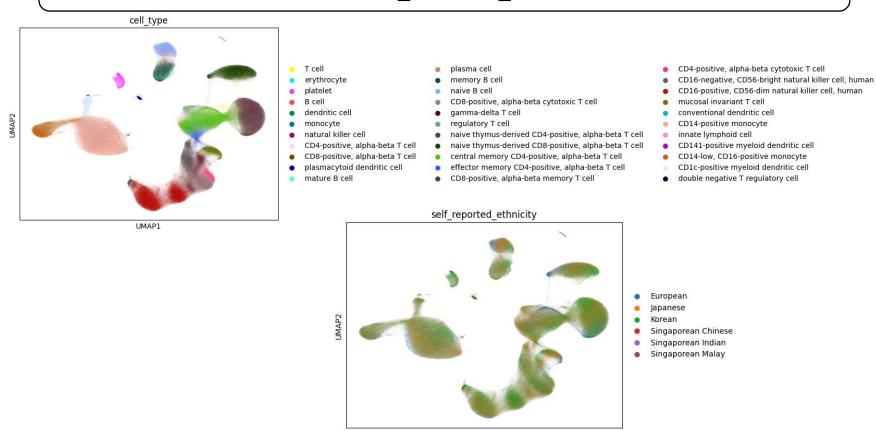
- 処理の流れ(Asian Immune Diversity Atlasのデータ)
 - 3. 読み込んだデータの確認

 $aida \triangleleft$

```
AnnData object with n obs \times n vars = 1058909 \times 36161 backed at 'AIDA.h5ad'
   obs: 'mapped reference assembly', 'alignment software', 'library uuid',
'assay ontology term id', 'library starting quantity', 'is primary data',
'cell type ontology term id', 'author cell type', 'sample uuid',
'tissue ontology term id', 'development stage ontology term id',
'sample derivation process', 'donor BMI at collection',
'suspension derivation process', 'suspension enriched cell types',
'suspension percent cell viability', 'suspension uuid', 'suspension type',
'donor id', 'self reported ethnicity ontology term id',
'donor living at sample collection', 'organism ontology term id',
'disease ontology term id', 'sex ontology term id', 'Country', 'nCount RNA',
'nFeature RNA', 'Ethnicity Selfreported', 'TCR VDJdb', 'TCRa V gene',
'TCRa D gene', 'TCRa J gene', 'TCRa C gene', 'TCRb V gene', 'TCRb D gene',
'TCRb J gene', 'TCRb C gene', 'TCR Clonality', 'TCR Clone ID', 'BCR VDJ V call',
'BCR VDJ D call', 'BCR VDJ J call', 'BCR VDJ C call', 'BCR VJ V call',
'BCR VJ J call', 'BCR VJ C call', 'BCR Clonality', 'BCR Clone size',
'BCR mu freq', 'tissue type', 'cell type', 'assay', 'disease', 'organism', 'sex',
'tissue', 'self reported ethnicity', 'development stage', 'observation joinid'
   var: 'feature is filtered', 'feature name', 'feature reference',
'feature biotype', 'feature length', 'feature type'
   uns: 'citation', 'default embedding', 'schema reference', 'schema version',
'title'
   obsm: 'X umap'
```

- 処理の流れ (Asian Immune Diversity Atlasのデータ)
 - 4. scanpy上での解析(以下はデータに含まれている UMAPプロットの作成)

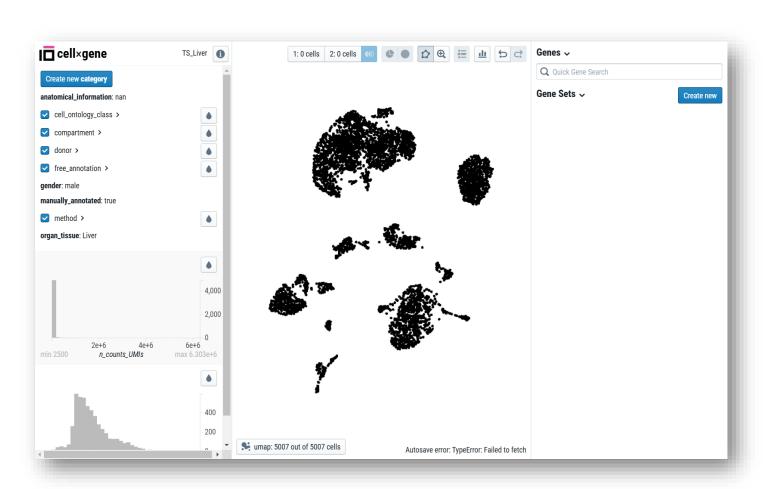
```
scanpy.pl.umap(aida,color='cell_type') 4
scanpy.pl.umap(aida,color='self_reported_ethnicity') 4
```



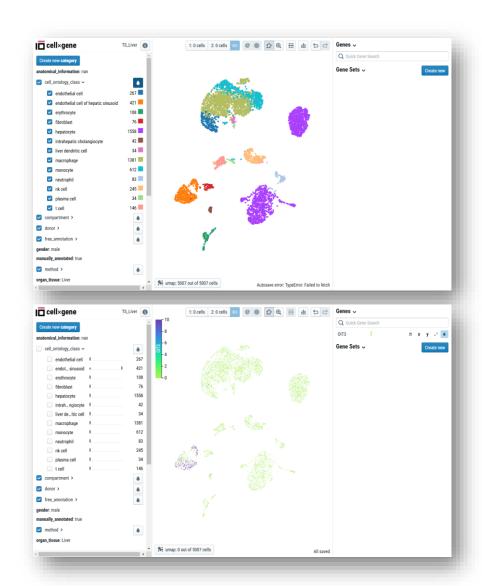
ダウンロードしたファイルを解析ソフトウェアで使う

ダウンロードしたH5ADファイルを cellxgene で使う

- cellxgene (https://github.com/chanzuckerberg/cellxgene)
 - ・シングルセルRNA-seqの結果(クラスタリングや細胞アノテーション情報)を参照したり、 自分で細胞へのアノテーションを付与したりできるウェブベースのツール



cellxgene (https://github.com/chanzuckerberg/cellxgene)



提供されている細胞アノテーション による色付け表示

(自分で細胞アノテーション/カテゴリ分けを行うこともできる)

指定した遺伝子の発現量による 色付け表示

- cellxgeneで必要となるH5ADファイルの要件
 - Matrix data (usually raw or normalized expression values) in anndata.X
 - At least one embedding (e.g., tSNE, UMAP) in anndata.obsm, specified with the prefix X_ (e.g., by default scanpy stores UMAP coordinates in anndata.obsm['X umap'])
 - A unique identifier is required for each cell, which by default will be pulled from the obs DataFrame index. If the index is not unique or does not contain the cell ID, an alternative column can be specified with --obs-names
 - A unique identifier is required for each gene, which by default will be pulled from the var DataFrame index. If the index is not unique or does not contain the gene ID, an alternative column can be specified with --var-names

https://cellxgene.cziscience.com/docs/05__Annotate%20and%20Analyze%20Your%20Data/5_3__Preparing %20Data

cellxgene のインストール (pipが利用可能とする)

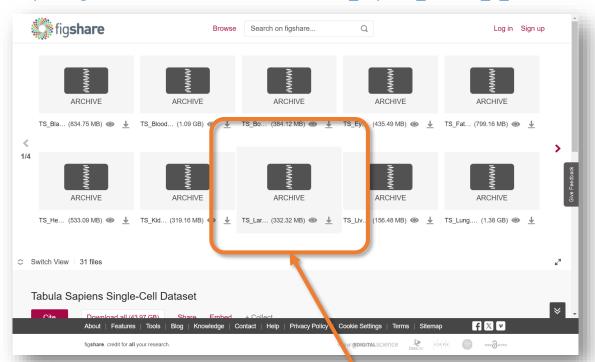
\$ pip install cellxgene⊲

他の方法でのインストール方法については(Docker利用等)、以下を参照

https://cellxgene.cziscience.com/docs/05__Annotate%20and%20Analyze%20Your%20Data/5_1__Getting%20Started:%20Install,%20Launch,%20Quick%20Start

- 処理の流れ(Tabula sapiensのLiverデータ)
 - 1. H5AD形式のファイルのダウンロード(figshareより)

https://figshare.com/articles/dataset/Tabula Sapiens release 1 0/14267219



下向き矢印のアイコンをクリックするとZIPファイルがダウンロードされるので unzipコマンドや、7-zip等のツールで展開すると "TS_Liver.h5ad" というファイル が作成される

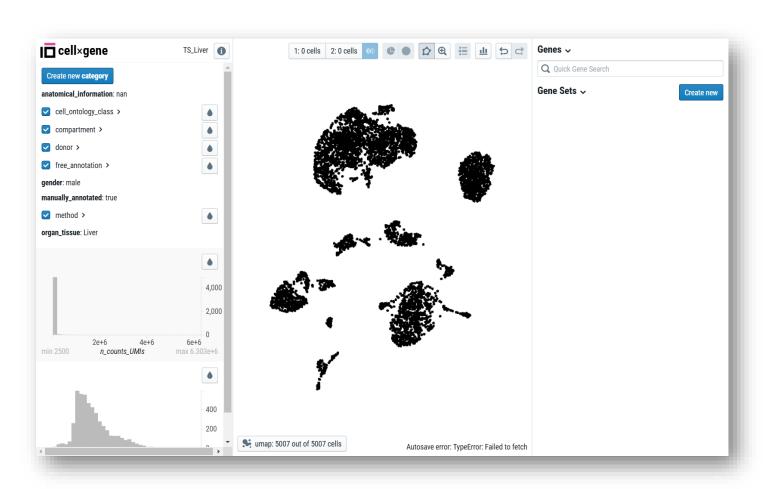
- 処理の流れ(Tabula sapiensのLiverデータ)
 - 2. cellxgene の起動

```
$ cellxgene launch TS_Liver.h5ad
```

```
[cellxgene] Starting the CLI...
[cellxgene] Loading data from TS_Liver.h5ad, this may take a while...
[cellxgene] Warning: Annotate data matrix is sparse, but not a CSC (columnar) matrix.
Performance may be improved by using CSC.
[cellxgene] Warning: Var annotation 'gene_symbol' has 57316 categories, this may be cumbersome or slow to display. We recommend setting the --max-category-items option to 500, this will hide categorical annotations with more than 500 categories in the UI WARNING:root:Type float64 will be converted to 32 bit float and may lose precision.
WARNING:root:Type float64 will be converted to 32 bit float and may lose precision.
WARNING:root:Type float64 will be converted to 32 bit float and may lose precision.
[cellxgene] Launching! Please go to http://localhost:5005 in your browser.
[cellxgene] Type CTRL-C at any time to exit.
```

このアドレスをGoogle Chrome等のウェブブラウザで開く

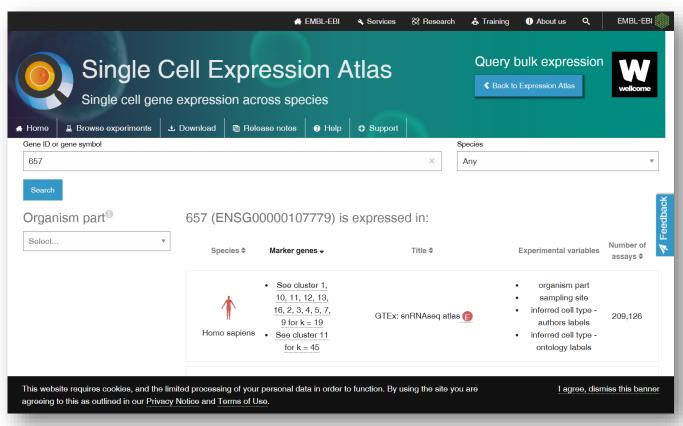
- 処理の流れ (Tabula sapiensのLiverデータ)
 - 3. ウェブブラウザでの表示



シングルセルRNA-seq解析に有用なウェブサイト

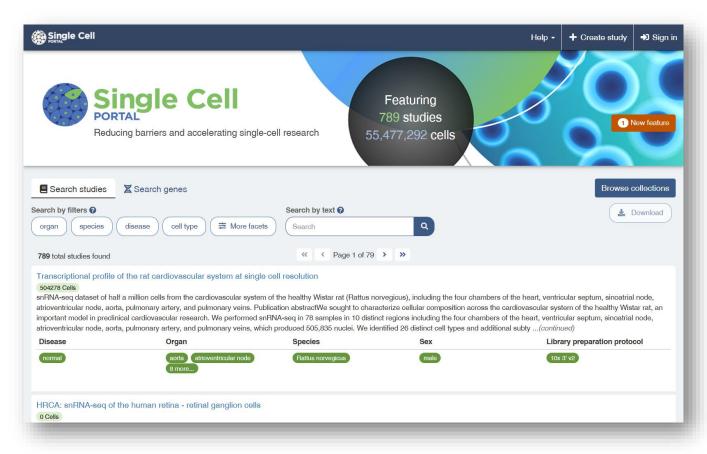
EBI – Single-cell Expression Atlas

- https://www.ebi.ac.uk/gxa/sc/
- ・様々な生物種の公開シングルセルRNA-seqデータを収集して再解析し、 例えば、遺伝子名等でデータセット横断的に検索して、マーカー遺伝子や細胞 クラスターの情報などが見られるようにしたウェブサイト



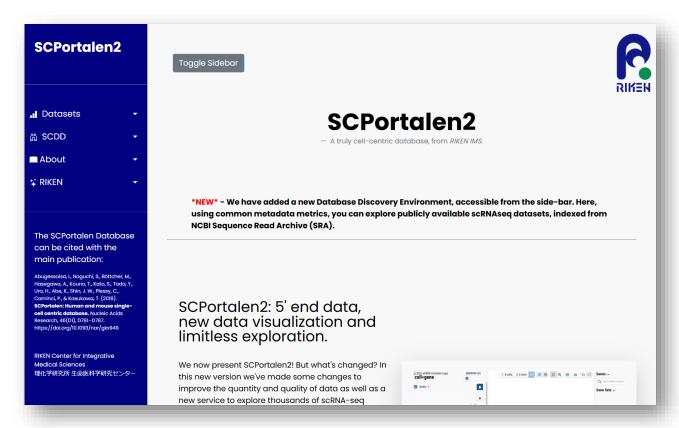
Broad Institute – single-cell portal

- https://singlecell.broadinstitute.org/
- ・公開シングルセルRNA-seqデータの再解析を行い、各データセットごとのクラスタリング結果の図を参照したり、興味のある遺伝子について細胞ごとの発現プロファイルを参照したりできるウェブサイト



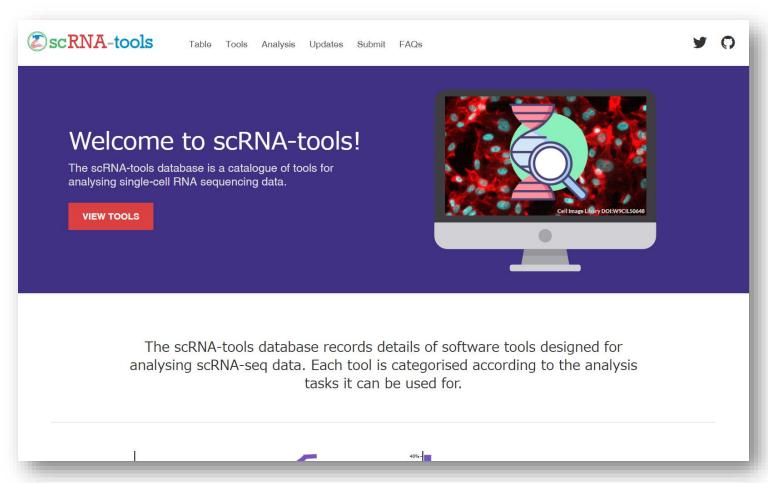
RIKEN – scPortalen 2

- https://single-cell.riken.jp/
- ・公開シングルセルRNA-seqのメタデータの修正や再計算を行い、再利用を 促進することを目的としたデータベース
- ・解析結果のダウンロードやCellxGeneでの参照などが可能となっている



scRNA-tools

- https://www.scrna-tools.org/
- シングルセルRNA-seqの解析に用いられる様々なソフトウェアに関する データベース



まとめ - Take-home messages

- すでに多くのシングルセルRNA-seqのデータが公共リポジトリ等から入手 可能である
 - INSDC (DDBJ / NCBI / EMBL-EBI)
 - Human Cell Atlas 関連サイト
 - 10x Genomics 社の提供するデータセット など
- ・これらを利用することで今からでもシングルセルRNA-seqのデータ解析が スタートできる
 - ・データ解析手法の勉強
 - 自分の研究対象に近いデータセットを解析することで、研究の見通しを立てられる
- シングルセルRNA-seqは関連情報も多く存在する
 - ・シングルセルRNA-segデータや解析方法も用意に入手可能
 - ただし、シングルセルRNA-seqの解析手法の取得も重要であるが、常にアップデートし続けていくことも重要